

PhishGuard IA

Sistema Inteligente de Análise e Prevenção de Fraudes Digitais

Relatório Técnico

Atividade Externa à Disciplina – Inteligência Artificial

Thales Moura Machado Caixeta

Pontifícia Universidade Católica

2026

1. Introdução

Com o avanço da transformação digital e a crescente utilização da internet para atividades financeiras, comerciais e pessoais, os golpes digitais tornaram-se uma das principais ameaças à segurança da informação na sociedade contemporânea. Técnicas como phishing, engenharia social, páginas falsas, fraudes via PIX e mensagens fraudulentas vêm causando prejuízos financeiros e danos emocionais a milhões de pessoas.

Grande parte desses ataques explora fatores humanos, utilizando mensagens manipulativas, senso de urgência e falsas promessas para enganar os usuários. Em muitos casos, pessoas sem conhecimento técnico possuem dificuldade para identificar conteúdos suspeitos, tornando-se vulneráveis a fraudes digitais cada vez mais sofisticadas.

Nesse contexto, o presente projeto propõe o desenvolvimento do **PhishGuard IA**, um sistema inteligente de análise e prevenção de golpes digitais baseado em IA heurística, com o objetivo de auxiliar usuários na identificação de possíveis ameaças digitais em tempo real.

2. Contextualização do Problema

O crescimento acelerado da conectividade digital trouxe inúmeros benefícios para a sociedade, porém também ampliou significativamente a atuação de criminosos virtuais. O Brasil consolidou-se como um dos principais alvos de engenharia social do planeta, com foco na manipulação psicológica das vítimas.

Estatísticas relevantes sobre golpes digitais no Brasil:

- Quase 7 milhões de tentativas de fraude em um semestre — média de 4.600 por hora (Serasa Experian)
- Brasil detém 62% de todos os ataques de phishing direcionados à América Latina (Kaspersky)
- 80% das URLs maliciosas duram menos de 2 horas online, dificultando o bloqueio por sistemas tradicionais
- 83,2% dos brasileiros têm medo de sofrer golpe na internet — superando o medo de assalto à mão armada (Fórum Brasileiro de Segurança Pública / Datafolha)
- Prejuízo de R\$ 4,5 bilhões anuais em golpes no ecossistema PIX (Febraban)
- Prejuízo médio individual de R\$ 6.311 por vítima
- 24% da população brasileira com mais de 16 anos já foi vítima de golpe virtual (DataSenado)

Tipos de golpes mais comuns:

- Phishing bancário — mensagens com alertas falsos de conta suspensa ou compra não reconhecida

- Golpe do falso benefício social — links fraudulentos para roubo de CPF e dados pessoais
- Fraude de reversão de PIX — simulação de depósito errado para forçar devolução imediata
- Links falsos com domínios suspeitos e clonagem de páginas oficiais
- Engenharia social ativa e falsos avisos de bloqueio de conta

3. Objetivo Geral e Objetivos Específicos

Desenvolver um sistema inteligente de detecção de golpes digitais utilizando Inteligência Artificial heurística para analisar mensagens e links suspeitos, identificando possíveis fraudes e alertando os usuários sobre riscos digitais em tempo real.

Objetivos específicos:

- Desenvolver uma interface web simples e acessível para análise de mensagens suspeitas
- Identificar padrões comuns de phishing e engenharia social
- Classificar o nível de risco das mensagens analisadas (Baixo, Médio, Alto)
- Detectar elementos suspeitos presentes nos conteúdos enviados
- Fornecer explicações claras sobre os riscos encontrados
- Apresentar recomendações de segurança personalizadas ao usuário
- Demonstrar a aplicação prática da Inteligência Artificial na cibersegurança

4. Público-Alvo e Personas

Para orientar o desenvolvimento do PhishGuard IA, foram estruturadas duas personas baseadas em perfis reais extraídos do cenário estatístico brasileiro:

Persona 1 — Seu Geraldo, 68 anos (Usuário Vulnerável)

Aposentado que realiza todas suas interações bancárias e familiares pelo smartphone. Possui baixo letramento digital e sente extrema dificuldade em diferenciar comunicações oficiais de mensagens fraudulentas. Vive sob constante ansiedade de perder economias de uma vida inteira — impacto que, em idosos, costuma ser 5 vezes maior do que em adultos jovens.

Benefício do PhishGuard IA: A interface simples com classificação visual de cores (Risco Alto/Baixo) permite que Seu Geraldo cole qualquer mensagem suspeita do WhatsApp antes de agir, funcionando como um escudo imediato de proteção.

Persona 2 — Mariana, 31 anos (Profissional Autônoma)

Arquiteta autônoma e usuária intensa de canais digitais para captação e fechamento de contratos. Recebe diariamente dezenas de mensagens de números desconhecidos alegando ser novos clientes ou fornecedores. Com a correria do dia a dia, não tem tempo para investigar a idoneidade de cada link recebido.

Benefício do PhishGuard IA: O sistema detecta em segundos os elementos que tornam uma proposta suspeita — linguagem de urgência extrema, domínios camuflados — permitindo que Mariana filtre ameaças sem paralisar sua produtividade.

5. Metodologia

O desenvolvimento do projeto foi realizado por meio de uma abordagem prática baseada em pesquisa aplicada e prototipagem funcional. Inicialmente, foi realizada uma análise sobre os principais tipos de golpes digitais atualmente utilizados em ambientes virtuais.

Foram estudados padrões frequentemente presentes em fraudes digitais, como linguagem de urgência extrema, solicitação de dados sensíveis, promessas de benefícios financeiros, links suspeitos e tentativas de engenharia social. Com base nesses padrões, foi desenvolvido o protótipo funcional utilizando tecnologias web e técnicas de análise heurística associadas à Inteligência Artificial.

O protótipo funcional está disponível publicamente em:

<https://thales-caixeta.github.io/phishguard/>

6. Funcionamento do Sistema (MVP)

O PhishGuard IA funciona por meio da análise heurística de mensagens e links suspeitos enviados pelo usuário. O sistema identifica padrões linguísticos e comportamentais frequentemente associados a golpes digitais.

Etapa	Descrição
1	O usuário insere uma mensagem ou link suspeito no campo de análise
2	O sistema processa o conteúdo com regras heurísticas e padrões de fraude
3	São identificados elementos suspeitos presentes na mensagem
4	O sistema calcula um score de risco de 0 a 100%
5	O usuário recebe análise detalhada e recomendações de segurança

Indicadores detectados pelo sistema:

- Linguagem manipulativa e senso de urgência extrema
- Solicitação de senhas, CPF e credenciais bancárias
- Menções financeiras suspeitas (PIX, transferências, valores monetários)
- Links com domínios fraudulentos ou encurtados

- Promessas de prêmios e benefícios financeiros
- Padrões específicos de golpe via PIX
- Excesso de exclamações e texto em caixa alta (CAPS LOCK)

7. Demonstração do Protótipo em Funcionamento

A seguir são apresentadas capturas de tela do PhishGuard IA em operação, demonstrando a análise de diferentes tipos de mensagens suspeitas e legítimas:




Figura 1 — Análise de golpe de falso benefício social (Risco ALTO · 100%)



PhishGuard IA

Sistema inteligente de detecção de golpes digitais

Análise por IA heurística

MENSAGEM OU LINK SUSPEITO

URGENTE! Sua conta bancária foi suspensa por atividade suspeita. Clique agora para regularizar: <http://bradesco-seguro.xyz/verificar?token=abc123>. Caso não acesse em 24h, sua conta será bloqueada definitivamente e todos os seus dados serão perdidos.

EXEMPLOS PARA TESTAR

Link phishing

SMS fraude

E-mail falso

PIX falso

Mensagem legítima

Analisar agora

Risco ALTO

Alta probabilidade de golpe digital

Baixo risco

95% de risco

Alto risco

ELEMENTOS DETECTADOS

Linguagem de urgência extrema

Solicitação de dados sensíveis

URL com palavra-isca

ANÁLISE DETALHADA

Esta mensagem apresenta múltiplos indicadores fortemente associados a golpes digitais: uso de urgência extrema, promessas de benefícios, solicitação de dados sensíveis e/ou links com domínios fraudulentos. Este é um padrão clássico de phishing ou engenharia social. Não interaja com esta mensagem.

RECOMENDAÇÕES DE SEGURANÇA

✔ Não clique em nenhum link desta mensagem — delete-a imediatamente.

✔ Nunca forneça senha, CPF, dados do cartão ou código de autenticação.

✔ Se recebeu isso como e-mail, marque como spam e reporte ao seu provedor.

✔ Se acredita que seus dados foram comprometidos, entre em contato com seu banco imediatamente.

✔ Você pode denunciar golpes digitais na delegacia virtual do seu estado ou pelo SaferNet Brasil.

Analisar outra mensagem

Figura 2 — Análise de phishing bancário com domínio suspeito (Risco ALTO · 95%)




Figura 3 — Análise de e-mail falso de cancelamento de compra (Risco ALTO · 81%)




Figura 4 — Análise de golpe de reversão de PIX (Risco ALTO · 78%)




Figura 5 — Análise de mensagem legítima (Risco BAIXO - 0%)

8. Ferramentas de IA Utilizadas

O desenvolvimento do projeto contou com o apoio estratégico de três ferramentas de Inteligência Artificial Generativa, cada uma com responsabilidades específicas:

Ferramenta de IA	Responsabilidade no Projeto
ChatGPT (OpenAI)	Estruturação acadêmica do relatório, refinamento técnico da escrita, organização das seções e fundamentação teórica.
Gemini (Google)	Pesquisa de mercado, levantamento de estatísticas sobre golpes no Brasil, tendências de cibersegurança e construção das personas.

Claude (Anthropic)	Desenvolvimento do protótipo funcional, implementação da interface web, lógica de detecção heurística e análise em tempo real.
---------------------------	--

Tecnologias utilizadas no protótipo: HTML, CSS, JavaScript e algoritmos de análise heurística baseados em padrões de IA.

9. Viabilidade Técnica

O projeto apresenta alta viabilidade técnica devido à utilização de tecnologias acessíveis e de baixo custo computacional. Por se tratar de uma aplicação web leve, o sistema pode ser facilmente adaptado para:

- Extensões de navegador para verificação automática de links durante a navegação
- Aplicativos mobile para análise de mensagens recebidas no WhatsApp e SMS
- Bots de verificação integrados a plataformas de comunicação corporativa
- Plataformas de segurança digital para instituições financeiras
- Ambientes educacionais para conscientização sobre golpes digitais

O PhishGuard IA não exige infraestrutura avançada nem treinamento complexo de modelos próprios de IA, tornando sua implementação econômica e escalável. A proposta tem potencial de impacto direto nos R\$ 4,5 bilhões anuais em prejuízos com golpes digitais no Brasil.

10. Análise Ética

A utilização de Inteligência Artificial em sistemas de segurança digital exige cuidados relacionados à privacidade, transparência e responsabilidade tecnológica. O PhishGuard IA foi desenvolvido considerando os seguintes princípios éticos:

Privacidade de Dados (Privacy by Design)

O conteúdo analisado não é armazenado permanentemente pelo sistema. A análise ocorre localmente no navegador, sem transmissão de informações sensíveis para servidores externos, protegendo a privacidade do usuário em conformidade com a LGPD.

Supervisão Humana

O sistema não toma decisões definitivas sobre bloqueios ou punições. Seu objetivo é alertar o usuário sobre possíveis riscos, preservando a autonomia e a responsabilidade humana na decisão final.

Transparência da IA (IA Explicável — XAI)

O PhishGuard IA fornece explicações claras sobre os fatores que levaram à classificação de risco, seguindo o princípio de Inteligência Artificial Explicável (XAI), que garante que as

decisões do sistema sejam compreensíveis ao usuário.

Mitigação de Falsos Positivos

O sistema reconhece que existe a possibilidade de mensagens legítimas serem classificadas como suspeitas. Por isso, atua como ferramenta de apoio preventivo — e não como mecanismo absoluto de validação — incentivando sempre a verificação em canais oficiais.

Conscientização Digital

Além da detecção de fraudes, o projeto possui caráter educacional, incentivando os usuários a desenvolverem maior consciência sobre golpes digitais e práticas seguras na internet.

11. Conclusão

O projeto PhishGuard IA demonstrou a viabilidade da utilização de Inteligência Artificial heurística no auxílio à prevenção de golpes digitais. Por meio de uma interface simples e acessível, o sistema consegue identificar padrões suspeitos em mensagens e links, classificando riscos e fornecendo orientações de segurança personalizadas.

A proposta evidencia como tecnologias de Inteligência Artificial podem contribuir para a proteção digital da população, especialmente diante do cenário alarmante: 7 milhões de tentativas de fraude por semestre, prejuízo médio de R\$ 6.311 por vítima e 83,2% dos brasileiros com medo de golpes virtuais.

Além da aplicação prática, o projeto reforça a importância da ética, da privacidade e da transparência no desenvolvimento de soluções baseadas em IA. O PhishGuard IA possui potencial real de evolução como ferramenta de conscientização e apoio à segurança digital da sociedade brasileira.

Referências

- Serasa Experian — Indicador de Tentativas de Fraude no Brasil
- Kaspersky — Relatório de Ameaças Cibernéticas na América Latina
- Febraban — Federação Brasileira de Bancos — Dados sobre Fraudes no PIX
- Fórum Brasileiro de Segurança Pública / Datafolha — Pesquisa de Percepção de Segurança
- DataSenado — Pesquisa sobre Golpes Virtuais no Brasil
- Lei Geral de Proteção de Dados (LGPD) — Lei nº 13.709/2018
- CERT.br — Cartilhas de Segurança para Internet
- Conceitos de Engenharia Social, Phishing e IA Explicável (XAI)